

Дистилляция разнородных моделей в глубоком обучении

Набиев Мухаммадшариф Фуркатович
Научный руководитель: к.ф.-м.н. О. Ю. Бахтеев

Московский физико-технический институт
Кафедра интеллектуальных систем ФПМИ МФТИ

2025

Цель исследования

Проблема: Методы дистилляции для *разнородных* архитектур (например, $RNN \leftrightarrow CNN$) обычно сопоставляют отдельные признаки, но слабо учитывают **распределение** скрытых представлений и их **поток** по слоям.

Цель: Предложить метод дистилляции разнородных моделей учитывающий распределение скрытых представлений.

Решение: Свести набор скрытых состояний к компактным матричным статистикам и выровнить их учитывая стоимость и вес переноса.

Постановка задачи

Пусть $\mathfrak{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ – набор изображений. Рассмотрим две модели R (RNN) и C (CNN). Их скрытые представления:

$$\mathbf{h}_1^R, \dots, \mathbf{h}_K^R \in \mathbb{R}^{D_1} \quad \text{и} \quad \mathbf{A}_1^C, \dots, \mathbf{A}_N^C \in \mathbb{R}^{D_2}$$

Для агрегации скрытых переменных введем

$$\mathbf{F}_k^R = \mathbf{u}_k \mathbf{u}_k^T \in \mathbb{R}^{d \times d}, \quad \text{где } \mathbf{u}_k = \text{aggr}(\mathbf{h}_1^R, \dots, \mathbf{h}_K^R) \in \mathbb{R}^d$$

$$\mathbf{F}_j^C = \frac{1}{P_j} \mathbf{B}_j \mathbf{B}_j^T \in \mathbb{R}^{d \times d}, \quad \text{где } \mathbf{B}_j = \text{Flatten}(\text{Conv}(\mathbf{A}_j^C)) \in \mathbb{R}^{d \times P_j}$$

Имея набор агрегированных матриц определим матрицу стоимости $\mathbf{C} \in \mathbb{R}^{K \times N}$, как $C_{kj} = \|\mathbf{F}_k^R - \mathbf{F}_j^C\|_F^2$ и матрицу весов $\mathbf{\Gamma} = \text{Softmax}(-\mathbf{C})$. Минимизируем следующую функцию потерь,

$$\mathcal{L} = \mathcal{L} + \lambda \mathbb{E}_{\mathbf{x}} \sum_{k=1}^K \sum_{j=1}^N \Gamma_{kj}(\mathbf{x}) C_{kj}(\mathbf{x})$$

В зависимости от выбора учителя (RNN или CNN) можно нормировать $\mathbf{\Gamma}$ по строкам или по столбцам.

FGMKD: цель исследования

Проблема

На практике при дистилляции есть компромисс: чем сильнее мы заставляем студента копировать учителей (**fidelity**), тем не всегда лучше **обобщение** (generalization).

Цель

Исследовать зависимость fidelity и generalization при дистилляции с ансамблем учителей.

Предложенный подход

Агрегировать учителей и обучать студента с коэффициентом λ перед KL, чтобы получать фронт fidelity-generalization по λ .

FGMKD: постановка задачи

Имеем данные $\mathfrak{D} = \{(\mathbf{x}_j, y_j)\}_{j=1}^n$, ансамбль учителей $\{T_i(\cdot | \mathbf{x})\}_{i=1}^M$ и студент $S_\theta(\cdot | \mathbf{x})$. Центроид учителей:

$$\hat{T}(\cdot | \mathbf{x}) = \frac{1}{M} \sum_{i=1}^M T_i(\cdot | \mathbf{x}).$$

Fidelity-метрики:


$$F_i(\theta) = \mathbb{E}_{\mathbf{x}} \text{KL}(T_i(\cdot | \mathbf{x}) \parallel S_\theta(\cdot | \mathbf{x})), \quad F_{\text{avg}}(\theta) = \frac{1}{M} \sum_{i=1}^M F_i(\theta),$$

$$F_{\text{cent}}(\theta) = \mathbb{E}_{\mathbf{x}} \text{KL}(\hat{T}(\cdot | \mathbf{x}) \parallel S_\theta(\cdot | \mathbf{x})).$$

Diversity (разброс учителей) и декомпозиция:


$$D_{\text{div}} = \mathbb{E}_{\mathbf{x}} \frac{1}{M} \sum_{i=1}^M \text{KL}(T_i(\cdot | \mathbf{x}) \parallel \hat{T}(\cdot | \mathbf{x})), \quad F_{\text{avg}}(\theta) = D_{\text{div}} + F_{\text{cent}}(\theta).$$

FGMKD: эксперименты



Обучение с центроидом дает прирост в качестве и в уменьшении KL.

FGMKD: эксперименты



Получили подтверждение оценки:

$$|R_{\text{sup}}(S_\theta) - R_{\text{sup}}(\hat{T})| \leq F_{\text{cen}}(\theta) + C(\delta) \varepsilon \sqrt{F_{\text{cen}}(\theta)}, \quad (1)$$

для подходящих констант $\in (0, 1)$ и $\varepsilon \geq 0$.

Дальнейшие исследования

Дистилляций разнородных моделей:

- ▶ Провести эксперименты на задаче классификации.
- ▶ Исследование влияний разных функций агрегаций.
- ▶ Дистилляция в двух направлениях.

FGMKD:

- ▶ Эксперименты на более сложных выборках.
- ▶ Взвешенное голосование учителей.
- ▶ Исследовать влияние плохих учителей.
- ▶ Учителя с ограниченным знанием (не знаю про существование остальных классов).
- ▶ Добавление шума в данных.