

Дистилляция разнородных моделей в глубоком обучении

Набиев Мухаммадшариф Фуркатович
Научный руководитель: к.ф.-м.н. О. Ю. Бахтеев

Московский физико-технический институт
Кафедра интеллектуальных систем ФПМИ МФТИ

2025

Цель исследования

Проблема: Методы дистилляции для *разнородных* архитектур (например, $RNN \leftrightarrow CNN$) обычно сопоставляют отдельные признаки, но слабо учитывают **распределение** скрытых представлений и их **поток** по слоям.

Цель: Предложить метод дистилляции разнородных моделей учитывающий распределение скрытых представлений.

Решение: Свести набор скрытых состояний к компактным матричным статистикам и выровнить их учитывая стоимость и вес переноса.

Постановка задачи

Пусть $\mathfrak{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ – набор изображений. Рассмотрим две модели R (RNN) и C (CNN). Их скрытые представления:

$$\mathbf{h}_1^R, \dots, \mathbf{h}_K^R \in \mathbb{R}^{D_1} \quad \text{и} \quad \mathbf{A}_1^C, \dots, \mathbf{A}_N^C \in \mathbb{R}^{D_2}$$

Для агрегации скрытых переменных введем

$$\mathbf{F}_k^R = \mathbf{u}_k \mathbf{u}_k^T \in \mathbb{R}^{d \times d}, \quad \text{где } \mathbf{u}_k = \text{aggr}(\mathbf{h}_1^R, \dots, \mathbf{h}_K^R) \in \mathbb{R}^d$$

$$\mathbf{F}_j^C = \frac{1}{P_j} \mathbf{B}_j \mathbf{B}_j^T \in \mathbb{R}^{d \times d}, \quad \text{где } \mathbf{B}_j = \text{Flatten}(\text{Conv}(\mathbf{A}_j^C)) \in \mathbb{R}^{d \times P_j}$$

Имея набор агрегированных матриц определим матрицу стоимости $\mathbf{C} \in \mathbb{R}^{K \times N}$, как $C_{kj} = \|\mathbf{F}_k^R - \mathbf{F}_j^C\|_F^2$ и матрицу весов $\mathbf{\Gamma} = \text{Softmax}(-\mathbf{C})$. Минимизируем следующую функцию потерь,

$$\mathcal{L} = \mathcal{L} + \lambda \mathbb{E}_{\mathbf{x}} \sum_{k=1}^K \sum_{j=1}^N \Gamma_{kj}(\mathbf{x}) C_{kj}(\mathbf{x})$$

В зависимости от выбора учителя (RNN или CNN) можно нормировать $\mathbf{\Gamma}$ по строкам или по столбцам.

Архитектуры и базовые методы


Архитектуры:

- ▶ **CNN**: три свёрточных блока (Conv-BN-ReLU-Pool), $K_C = 3$ промежуточных представления — нормированные матрицы Грама $\mathbf{F}_j \in \mathbb{R}^{d \times d}$.
- ▶ **RNN**: двухслойный GRU по строкам изображения, $K_R = 4$ скрытых состояния — матрицы ранга 1, $\mathbf{F}_k = \mathbf{u}_k \mathbf{u}_k^\top$.

Базовые методы:

- ▶ Только задача классификации — нижняя граница.
- ▶ Дистилляция по логитам — добавляет только выходной сигнал учителя.
- ▶ Жёсткое попарное соответствие слоёв — добавляет промежуточный сигнал, но с фиксированным соответствием слоёв $j^*(k) = \lfloor k \cdot K_S / K_T \rfloor$.
- ▶ Равномерная Γ : $\Gamma_{kj} = 1/(K_T K_S)$ — та же функция потерь, что и в предложенном методе, но без обучаемого выравнивания.


Результаты на CIFAR-10



- ▶ **RNN $\rightarrow$ CNN**: учитель слабее студента (0.672 vs 0.811) — все методы ухудшают результат.
- ▶ **CNN $\rightarrow$ RNN**: учитель сильнее (0.811 vs 0.672) — все методы дают прирост.

Матрица выравнивания Γ

Alignment matrix Γ (mean over 16 CIFAR-10 val images, seed=0)



Среднее по 16 изображениям val, seed = 0. Строки — слои учителя, столбцы — слои студента.

Анализ матрицы выравнивания

RNN → CNN:

- ▶ Γ вырождается в жёсткое соответствие: T0, T2, T3 сосредоточены на S1 (1.00), T1 — на S2 (0.99).
- ▶ Три из четырёх слоёв учителя направлены в один и тот же слой студента — вырожденное выравнивание.
- ▶ Слой S0 не получает никакого сигнала от учителя. Вероятно, именно это объясняет наибольший регресс и высокую дисперсию.

CNN → RNN:

- ▶ T0 и T1 (ранние слои учителя) делят массу между S0 и S1; T2 (поздний) концентрируется на S3 (0.78).
- ▶ Выравнивание структурировано и согласовано по глубине.

Дистилляция разнородных моделей:

- ▶ Анализ направления нормировки Γ (по строкам vs по столбцам).
- ▶ Исследование режима слабого учителя: при каком соотношении качеств учителя и студента дистилляция перестаёт помогать.
- ▶ Изучение причин нестабильности предложенного метода при $RNN \rightarrow CNN$.
- ▶ Исследование влияния различных функций агрегации.